《开源人工智能模型生态的数据分析》答辩 PPT 逐页设计文档

> *版本：V1｜适用场景：《大数据导论》课程项目答辩｜推荐规格：16:9、11 页正式汇报 + 3 页备份｜正式讲述约 7 分 50 秒，预留问答约 2 分钟。*
> *内容依据：项目仓库* `https://github.com/Wanru-P/HUST-` *的* `docs/ppt_handoff.md`、`docs/latex_report_materials.md`、`report_final.md`、`docs/supplementary_analysis.md` *和* `figures_final/`*。设计稿中的百分比和数字均须以* `data_hubstats/gold/analysis/results_manifest.json` *为最终对照，不能随意改写。*

一、总设计方案

1. 整套汇报的主线

314 万个公开 AI 模型，数量不断增加，但下载关注和模型继承并不是平均分布的。我们用 Spark 将公开快照转成可以核对的统计证据。

这套 PPT 不按照“背景—技术名词—五个实验各念一次—谢谢”的流水账排列，而按听众能自然理解的顺序推进：

1. 为什么要研究这么多模型（问题）
2. 怎么拿到和处理数据（方法）
3. 从数量、下载量、继承关系看见了什么（最强的三个结果）
4. 模型属性、任务类别还能告诉我们什么（补充结果）
5. Spark 真正解决了哪些处理问题、结果靠不靠谱（课程技术重点）
6. 哪些结论成立，哪些不能过度解释（总结）

整套的主结论不是“AI 模型越来越多”，而是“模型生态在供给数量、下载注意力和底座复用三个维度存在明显差异”。

2. 视觉规范（给 PPT 成员）

- 页面：16:9，13.333 × 7.5 英寸。四边留 0.55–0.65 英寸，页脚 0.30 英寸，内容右边界统一。
- 整体：**高校计算机课程答辩 / 数据研究可视化**。白底为主，避免 AI 生成感的通栏渐变、巨型圆角卡片、漂浮科技粒子与过量图标。
- 背景：`#FFFFFF`；浅灰蓝背景仅用于图旁注释 `#F4F7FA`。

- 主色：深海军蓝 `#173653`，辅助蓝 `#3778B3`，弱蓝 `#8AB8DC`；HF 品牌黄 `#F3B945` 仅标出一次关键结论。正文 `#263444`，注释 `#697788`，分隔线 `#DCE5ED`。
- 字体：中文优先微软雅黑 / 思源黑体，英文 Aptos / Arial；标题 27–30 pt，副结论 17–19 pt，正文 16–19 pt，图注 11–13 pt，数字主视觉 40–56 pt。不要出现小于 11 pt 的关键信息。
- 统一页眉：左上方一句**结论型标题**，其下一行用 12–13pt 灰色标签 `01 / DATA`、`02 / ANALYSIS` 等（这是小型章节标识，不是装饰徽章）。除封面外页底右侧小号页码。
- 图表：优先直接使用仓库 `figures_final/*.svg` / `*.pdf`，需要改版时按原数据重新绘制；禁止将图像生成模型生成的“曲线图”当作真实实验图。去掉原图内部过多标题可通过规范化重绘，不得裁断坐标、轴标签和数值。
- 视觉层级：每页只强调**一个结论**和最多 2–3 个数字。图表占主体；不再重复放整段摘要。
- 动画：仅保留少量“淡入”“依次出现”；同一页最多 2–3 次点击，不使用飞入、弹跳、眩光。讲述顺序与元素出现顺序一致。
- 图标：GitHub、Hugging Face 品牌真实矢量图。Spark 可使用 Apache Spark 官方图标。其余使用简洁线性图标即可，但不是每页都需图标。

3. 页数与时间

页码	页面标题（结论型标题）	推荐时长	主素材
01	开源人工智能模型生态的数据分析	15秒	标题 + 极简模型节点插画
02	314 万个模型，值得研究的不只是数量	40秒	三个核心问题
03	从公开快照到可复现分析，我们怎样处理数据	50秒	Bronze → Silver → Gold 流程图
04	模型数量持续增长，但快照不是完整历史	40秒	Figure 01
05	前 1% 的模型获得了 97.13% 的近 30 天下载量	55秒	Figure 05
06	近 92 万条显式继承关系，连接起模型家族	55秒	Figure 07
07	模型属性与下载量有关联，但不是未来热度预测	40秒	Figure 09

页码	页面标题（结论型标题）	推荐时长	主素材
08	不同任务类型的模型数量和继承比例并不相同	40秒	Figure 04
09	Spark 的性能差异来自算子和数据规模，不只是核数	50秒	Figure 10 / Figure 11
10	比“跑通”更重要：优化瓶颈并核对结果	55秒	问题→修改→验证三组对照
11	结论与边界：规模、集中、继承	30秒	三条结论 + 三条限制
合计		**7分50秒**	预留约 10 秒容错

二、正式页面逐页设计

第 01 页｜封面（15 秒）

标题： 开源人工智能模型生态的数据分析
副标题： 基于 Hugging Face 公开模型快照的 Spark 大数据实验

讲述目的： 让评委立刻明白数据源、研究对象、课程技术，不要让封面显得像商业 AI 宣传海报。

版式与位置：

- 采用左侧约 65% 主标题、右侧约 35% 简洁节点关系插画；文字整体稍偏上，不必垂直居中。
- 左上角放一行小字：“大数据导论 · 课程项目答辩”。主标题两行，深蓝 34–38pt，加粗。
- 标题下方一行副标题 17–18pt；右侧绘制 1 个深蓝底座节点与若干浅蓝衍生节点。**示意插画不是实验谱系数据，不标人数或比例。**
- 页面最下部显示学校、班级、汇报人、团队成员、日期（依据最终确认信息填写；不要误将项目题目写成课程名）。右下角可放 Hugging Face 小图标。

页面上可直接放的文字：

> *开源人工智能模型生态的数据分析*
> *基于 Hugging Face 公开模型快照的 Spark 大数据实验*
> *《大数据导论》课程项目答辩*

讲述提示： “我们这次分析的是 Hugging Face 上公开可见的 AI 模型，用 Spark 处理了 314 万级的模型记录，重点研究模型增长、下载量和继承关系。”

不推荐： AI 脸部、机器人、蓝色电路板背景、过多科技光效、直接把 3 张分析图缩进封面。

第 02 页｜研究背景与问题（40 秒）

标题： 314 万个模型，值得研究的不只是数量

关键论点： “有多少模型”只是第一问；“注意力集中在哪里、哪些底座被不断复用”更值得追问。

版式与位置：

- 左侧 33%：大号 `3,138,954`（已去重模型数），下方小字“2026-10-10 数据快照中可见的公开模型”。不要写“全平台历史累计模型”。
- 右侧 67%：三个纵向问题，每个用小号 01/02/03 编号 + 一行加粗提问 + 一行灰色说明。分隔线而非圆角卡片。
- 底部一道细线：标注“另外比较不同任务类型、分析模型属性与下载热度的统计关联”，覆盖 RQ4/RQ5 而不列五大 RQ 的长清单。

页面直接用文案：

- **增长：** 模型供给是如何变化的?
- **关注：** 下载量是否集中在少数模型?
- **复用：** 哪些底座被大量衍生模型继承?
- *扩展分析：任务差异与模型属性的同期统计关联。*

讲述提示： “如果只统计数量，可能会忽略一个现象：模型越多，不代表下载量和影响范围越均衡。所以我们先看增长，再看下载，再看继承网络。”

必须说明： 截止日是**快照更新时间**，不是完整历史归档。

第 03 页｜数据来源、处理过程和技术栈（50 秒）

标题： 从公开快照到可复现分析，我们怎样处理数据

核心数值： `3,138,959` 源物理行 → `3,138,954` 去重模型； `1.49 GiB` 原始 Parquet； `20,625,635` 标签行； `919,839` 血缘边。

版式与位置：

- 上半部占 70%：画横向四段管线，空间比例约 18% / 25% / 28% / 23%，之间用细箭头：
  1. **Hugging Face / Bronze**： `models.parquet` 、原始只读；
  2. **Spark / Silver**：Schema 适配、按 ID 去重、展开 `tags` / `baseModels` ；

3. **Gold / 统计表**：月度趋势、Lorenz、谱系边、任务分组；
4. **分析输出**：GraphFrames、MLlib、可视化、报告。

- 流程节点使用白色留白块、深蓝色段落标题和细蓝底线；不要画成立体数据库机器或太多齿轮。
- 下半部放 3–4 个紧凑数字对比（不是巨幅卡片）：源记录量、去重数量、标签行、血缘边。
- 最下方小字“运行：Windows 11 / PySpark 4.2.0 / local[6] / driver 3 GB”。

讲述提示： “我们不是直接拿 Excel 作图。先固定数据快照，Spark 负责读取、去重、字段整理和聚合，再把结果交给 GraphFrames、MLlib 和绘图脚本；这样统计口径可以复查。”

强调： `local[6]` 是单机多核执行，不能表述成多台机器组成的集群。

第 04 页｜RQ1 模型增长（40 秒）

标题： 模型数量持续增长，但快照不是完整历史

主素材： `figures_final/fig01_monthly_evolution.svg`（或高分辨率 PNG）。

版式与位置：

- 左侧约 72% 放完整的月度创建时间柱状图，图表底色纯白，坐标轴字体保证投影可读。
- 右侧约 28% 放两段极简“读图提示”：上面深蓝大数字 `125,030`；下面“2024 年 9 月：快照中创建时间落在该月的模型数量峰值”。再用一行灰字写“2026 年 10 月尚未结束，不应与完整月份直接比较”。
- 图中可用品牌黄色细线或箭头圈出 `2024-09` 的柱，但不改变原数据。

页面直接用文案：

> ***125,030***
> *2024 年 9 月，快照可见模型的创建数峰值*

讲述提示： “整体上，快照中近年创建的模型明显增多，2024 年 9 月达到一个高点。但这里统计的是当前仍可见模型的创建时间分布，不能把它当成完整历史发布记录。”

数据边界： `2022-03` 存在异常时间戳堆积、根因不明；若图显示这一点，脚注不要替它推断原因。备份页可放 Figure 02/03。

第 05 页｜RQ2 下载量集中（55 秒）

标题： 前 1% 的模型获得了 97.13% 的近 30 天下载量

主素材： `figures_final/fig05_lorenz.svg`（官方结果图，包含近 30 天与累计口径，讲述时重点突出近 30 天）。

版式与位置：

- 左侧约 65% 放完整 Lorenz 曲线，保持原坐标方向、图例和基准线；**不允许用不正确的“按降序排序 x 轴”示意图代替**。
- 右侧约 35%：主数字 `97.13%` 占据最明显区域，注释“Top 1% 模型所占近 30 天下载份额”。下面两行较小信息：`Gini = 0.995355`、`43.54%` 模型近 30 天下载为零。
- 大数字使用深蓝；97.13% 下方可用一条约 2pt 的金黄色强调线，不用整块黄色矩形。
- 最下部用小字写“downloads = 近 30 天下载量；长尾 ≠ 已通过幂律分布检验”。

讲述提示： “这一页是最有辨识度的结果。虽然模型很多，但最近 30 天的下载量高度集中，前 1% 的模型拿走了 97.13%。即使去掉零下载模型，补充验证仍显示明显集中，因此不是仅由零下载记录造成的。”

可选备用数据： 去掉零下载后 Gini 为 `0.991773`，**只在问答页展示**，不要在主页面堆四五组口径。

严禁： 写“97.13% 的用户只使用 1% 的模型”；下载次数不是独立用户数，下载量也不是模型质量。

第 06 页｜RQ3 模型继承网络（55 秒）

标题： 近 92 万条显式继承关系，连接起模型家族

主素材： `figures_final/fig07_family_network.svg`，该图内有全量统计和代表性家族子图两个部分。

版式与位置：

- 左侧 68%：用足够大的空间放 Figure 07。图内子图需清晰，不要把左右面板挤成豆腐块；如原图细节过密，可分离原始 SVG 的子区域重新排版，但不能修改统计。
- 右侧 32%：三条按行排列的数字，`919,839` “明确报告的 base → derived 关系”；`931,066` “参与这些关系的模型节点”；`43,419` “FLUX.1-dev 的直接衍生模型数”。
- 左下方增加一行小图例：深蓝代表底座 / 浅蓝代表衍生 / 箭头方向 `base → derived`（前提是与你放的真实图例一致）。
- 图旁简单标注“**示例家族子图**”，避免观众把代表性子图当成 93 万节点的全量网络可视化。

讲述提示： “除了下载量，我们还按照模型元数据明确声明的底座关系构建有向图。边表示底座指向衍生模型。最大的一类底座能被四万多个模型直接继承，说

明一部分底座承担了很强的复用作用。”

注意： 71.74% 模型缺少 `baseModels` 信息；不能说“剩余模型没有继承关系”。`children_count` 是直接子节点数量，不等于所有后代数。GraphFrames 的迭代算法已经全部完成，不能写成未完成。

第 07 页｜RQ4 模型属性与下载热度（40 秒）

标题： 模型属性与下载量有关联，但不是未来热度预测

主素材： `figures_final/fig09_ml_importance.svg`（特征重要性与模型对照）。

版式与位置：

- 左侧 62%：放 Figure 09 的模型对比 / 特征重要性双区。如果图中文本较密，可重新排为一张 4 行对照表加右侧简化特征图；数值保持一致。
- 右侧 38%：只放一个主结论 `R² = 0.6631`，标注“RandomForest / 独立测试集”；再放一行“Linear Regression 0.4177 · GBT 0.6313”。
- 底部横向细字：“样本 626,269；先划分训练/测试（约 8:2），仅在测试集评估。目标为 log(1 + downloads)。”
- 用一条小号醒目的限定语：“**同期统计关联 ≠ 预测未来下载量**”。

讲述提示： “我们也尝试用模型属性拟合当前快照中的下载量，随机森林在测试集上的 R^2 为 0.6631。但这只是同期关联，某些特征与下载量来自同一时点，因此不能直接拿这个成绩宣称能够预测模型未来会不会火。”

答疑备用： 时间切分的 sklearn 复验随机切分 R^2 0.6779 / 时间切分 0.5034；**两者是同一 sklearn 口径的对照**，不要直接用 Spark 的 0.6631 去计算相对下降。

第 08 页｜RQ5 不同任务类别（40 秒）

标题： 不同任务类型的模型数量和继承比例并不相同

主素材： `figures_final/fig04_library_task_structure.svg`；另用真实统计值制作简洁双行对比。

版式与位置：

- 上半部分 58%：Figure 04 在宽度约 90% 的区域居中，保证图例可读。
- 下半部分 42%：重点比较 **Text Generation** 与 **Text to Image** 两类（使用两行对比表，不要画错误的比例面积图）。

任务类型	快照可见模型数	已声明底座关系比例
Text Generation	422,224	46.38%
Text to Image	111,444	71.34%

- 表格最下一行灰字：“仅比较已标注任务；任务标签缺失 65.55%，统一视为 unknown，不参与任务间排序。”

讲述提示： “模型类型之间差别也很大。比如文生图类别中，声明底座关系的比例明显高于文本生成，这与这些任务中大量微调或衍生模型的使用方式有关。不过任务标签的缺失比例很高，所以我们只对有标签的模型做比较。”

事实边界： 最后一句关于原因只表述为“可能与……有关”或直接不做原因推断；分组统计本身不足以证明某种训练机制导致差异。

第 09 页｜Spark 性能实验（50 秒）

标题： Spark 的性能差异来自算子和数据规模，不只是核数

主素材： `figures_final/fig10_scale_runtime.svg` 和 `figures_final/fig11_partitions_perf.svg`。可选备用 Figure 12。

版式与位置：

- 使用两栏等宽并排：左 48% 放“规模与耗时”Figure 10，右 48% 放“shuffle 分区数与耗时”Figure 11，中间留 4% 空隙。
- 图下方各配一句读图结论。左“真实数据全列扫描：约 31 万条 0.797 s → 314 万条 4.891 s”；右“分区数不一定越多越好：相同算子 16 分区 2.558 s，64 分区 5.105 s”。
- 底部横向强调一个小实验：“**列裁剪**：314 万行，解码全列约 4.891 s，仅读 6 列约 0.567 s（约 8.6 倍）”。三段数据使用统一基准口径。
- 右下角脚注“本机 Windows / Spark local[6] / 多次测量报告中位数，非多节点扩展”。

讲述提示： “数据越多，扫描和 shuffle 的开销越明显。但我们也发现，优化并不是单纯增加分区数量。例如只读取需要的六列，就能大幅降低扫描时间。”

关键技术纠错： 比较列裁剪时必须使用**会实际解码数据列**的计时算子，不能用 Parquet `count(*)` 的元数据下推结果冒充扫描加速。图表中的秒数是算子基准测试，不是 142.8 秒全量 ETL 的耗时。

第 10 页｜工程问题与验证（55 秒）

标题： 比“跑通”更重要：优化瓶颈并核对结果

页面重点： 用具体例子证明项目不仅有结果，也处理过 Spark 的真实工程问题。

版式与位置：

- 不要把 8 条技术问题塞成两栏表格。用三条横向“问题 → 解决 → 验证结果”的证据条，每条高约 1.35 英寸，左 28%、中 43%、右 29%。中间细箭头、深浅蓝区分。

- 第一条“全局排序”：
  - 问题：对 314 万条模型使用全局窗口排名，数据压到单分区。
  - 调整：改为下载量频数聚合 + 并行恢复排名。
  - 验证：与旧算法逐行等价对照通过。
- 第二条“反复重算”：
  - 问题：多张 Gold 表重复读 Bronze 原始数据。
  - 调整：Bronze 只读一次，写出 Silver，后续从磁盘回读。
  - 验证：样本 ETL `193 s → 50.7 s`（同一项目的改造前后对照，不是完整 ETL）。
- 第三条“图算法开销”：
  - 问题：近百万节点下迭代图算法计算成本高。
  - 调整：GraphFrames 独立脚本、超时看门狗、分步骤持久化。
  - 验证：6 个迭代步骤最终全部运行完成。
- 页底一行可信度补充：“约 5 万条确定性样本进行 13 项 Spark ↔ pandas ETL 对照测试；正式结果由统一结果清单驱动。”

讲述提示： “这里我们不想只给出一组漂亮数字。在处理中遇到过全局排序单分区、重复扫描和大图迭代计算的问题，后来逐一调整算法和执行流程，并做等价性测试。我们也因此体会到，处理效率和结果正确性需要同时考虑。”

可替换案例： 如果答辩更注重‘系统配置’，可以把第三条换成“时区统一 UTC 与 TimestampNTZ 适配”；但保留 GraphFrames 状态和事实，不能误写成运行失败。

第 11 页｜结论与局限（30 秒）

标题： 结论与边界：规模、集中、继承

版式与位置：

- 左侧 62%：三行总结，每行一个数字 + 一句话：
  1. `314 万`：规模可观，近年可见模型创建量增长；
  2. `97.13%`：近 30 天下载关注极度集中；
  3. `91.98 万`：公开声明的继承边连接出模型复用网络。
- 右侧 38%：竖排短标题“结果的适用范围”，三条限制：
  - 仅为固定快照，不能覆盖历史上下架模型；
  - 任务标签、底座信息存在较高缺失；
  - 单机 Spark 测试不能证明多节点扩展性能。

- 页底：一行“感谢聆听 · Q&A”，下方放 GitHub 仓库可点击短链接（如现场允许，可生成二维码，但二维码必须指向真实仓库）。

讲述提示： “总体来说，模型供给很大，但下载热度和底座复用明显不均衡。我们用 Spark 完成了全量处理和相关分析，也意识到快照缺失、标签缺失和单机环境会影响结论的解释。以上是我们的汇报，谢谢老师。”

不可写： “证明少数模型质量最好”“未来下载热度准确预测”“Spark 在多节点集群实现线性扩展”。

三、3 页备用答辩页（正式讲述不翻）

备用 A｜数据口径与质量：为什么不能把快照当历史？

- 标题：“我们究竟统计了哪些模型？”
- 左侧放时间轴 `2022-03 → 2026-10-10`，标注“当前快照中仍可见的模型的 createdAt”，不画作完整历史发行量。
- 右侧列三个限制：`pipeline_tag 缺失 65.55%`；`baseModels 缺失 71.74%`；`2022-03` 存在时间戳聚集异常，根因未证实。
- 备用问题：“为什么 2022 年第一月异常？”答：“我们确认时间戳聚集现象，但没有证据能确定根因，因此没有把它当作正常发布高峰。”

备用 B｜下载集中是不是因为零下载太多？

- 标题：“剔除零下载模型，集中度仍然很高”
- 主素材：`figures_supp/` 中 Gini 稳健性相关的 **Figure S1**（按仓库实际文件核对）。
- 简洁数据：全部模型 `Gini 0.995355`；剔除零下载后 `Gini 0.991773`；近 30 天零下载比例 `43.54%`。
- 回答：集中不是完全由零下载记录导致；但我们没有做严格幂律拟合，不能据此判断为幂律分布。

备用 C｜MLlib 结果与实验可信度

- 标题：“训练/测试怎样划分？结果是不是对未来有效？”
- 左半部分流程：`626,269 确定性采样 → 8:2 划分 → 仅在训练集 fit 预处理 → 测试集计算 R²`。
- 右半部分：`Spark RandomForest R² = 0.6631`；补充验证在**sklearn 同一实现口径**下随机切分 `0.6779`、创建时间切分 `0.5034`。
- 结论：“这一实验说明同快照属性与下载量有统计关联；时间切分结果下降提示对数据分布变化敏感，但不是未来下载热度的可靠预测。”

四、素材提取与制图清单

唯一数据准绳： `data_hubstats/gold/analysis/results_manifest.json` 。PPT 中任何数字如与设计稿不一致，先核对该结果清单及相应分析报告，不允许‘为了好看’取整修改关键口径。

页码	对应正式图片（优先 SVG/PDF 矢量）	用途
04	`figures_final/fig01_monthly_evolution.svg`	月度数量趋势
05	`figures_final/fig05_lorenz.svg`	下载量集中
06	`figures_final/fig07_family_network.svg`	继承关系与代表性家族
07	`figures_final/fig09_ml_importance.svg`	MLlib 模型对比
08	`figures_final/fig04_library_task_structure.svg`	任务差异
09	`figures_final/fig10_scale_runtime.svg`	规模与性能
09	`figures_final/fig11_partitions_perf.svg`	分区与性能
备用 A	`figures_final/fig02_task_growth.svg` 、 `fig03_task_time_heatmap.svg`	任务时间变化备用
备用 B	`figures_supp/` 下 Figure S1 的实际文件	下载集中稳健性
备用 C	`figures_supp/` 下 Figure S2 的实际文件	创建时间切分影响

源文件若只在仓库提供 PNG，可使用 300 dpi PNG；无须在不改变数据的前提下强制转换。所有原图进入 PPT 前检查中文字体嵌入、轴标签可读性、图例位置、原图标题与幻灯片标题是否重复。

建议素材目录：

```
ppt_delivery/
├── slides/                    # 交付 pptx
├── assets/
│   ├── figures_original/      # 仓库原始 Fig01–Fig12
│   ├── figures_for_ppt/       # 裁边后但不改变数值的可投影版本
│   └── brand/                 # GitHub / Hugging Face SVG or PDF
├── scripts/
│   ├── speaker_notes.md       # 汇报人口播稿
│   └── qa_backup.md           # 2 分钟答疑准备
└── design_spec.md             # 本文件
```